


哈夫曼树、哈夫曼编码

先导概念

概念一：什么是结点的路径长度


从根结点到该结点的路径上的连接数



结点k的路径长度就是从根结点A到结点k的路径上的连接数，也就是我们看到红色连边，也就是3。

概念二：什么是树的路径长度

就是树的每个叶子结点的路径长度之和



那么图中树的路径长度之和就是13.

概念三：什么是结点的带权路径长度？

结点的路径长度与结点权值的乘积。

比如规定结点K的权重/权值为4，结点K的路径长度为3，那么带权路径长度就是 $3 * 4 = 12$ 。

概念四：什么是树的带权路径长度 WPL

就是树的所有叶子结点的带权路径长度之和。

应用场景

在数据膨胀、信息爆炸的今天，数据压缩的意义不言而喻。谈到数据压缩，就不能不提赫夫曼（Huffman）编码，赫夫曼编码是首个实用的压缩编码方案，即使在今天的许多知名压缩算法里，依然可以见到赫夫曼编码的影子。

另外，在数据通信中，用二进制给每个字符进行编码时不得不面对的一个问题是如何使电文总长最短且不产生二义性。根据字符出现频率，利用赫夫曼编码可以构造出一种不等长的二进制，使编码后的电文长度最短，且保证不产生二义性。


当有了以上概念以后，我们就可以用WPL去判断一颗二叉树的性能。WPL的值越小，二叉树的性能越优。

哈夫曼树的构造过程


首先，出给一个初始森林：



第一步，森林中选择出两颗结点的权值最小的二叉树



第二步：合并两颗二叉树，增加一个新的结点作为新的二叉树的根，权值为左右孩子的权值之和。



第三步：不断的将新的结点跟权值最小的结点相结合

所以说，其实哈夫曼树其实很简单。我们说，哈夫曼编码可以有效的压缩数据（压缩率依赖于数据的特性在20%~~90%不等）。我们要讲哈夫曼编码，继续来看几个名词解释。

哈夫曼编码

定长编码

像ASCII编码、Unicode编码。ASCII编码每一个字符使用8个bit，能够编码256个字符；Unicode编码每个字符占16个bit，能够编码65536个字符，包含所有ASCII编码的字符。

假设我们要使用定长编码对由符号A，B，C，D和E构造的消息进行编码，对每个字符编码需要多少位呢？

至少需要3位，2个bit位不够表示五个字符，只能表示4个字符。

如果对DEAACAAAAABA进行编码呢？总共12个字符，每个字符需要3bit，总共需要36位。

定长编码的缺陷

浪费空间！对于仅包含ASCII字符的纯文本消息，Unicode使用的空间是ASCII的两倍，两种方式都会造成空间浪费；字符“a”和“e”的出现频率比“q”和“z”的出现频率高，但是他们都占用了相同位数的空间。要解决定长编码的缺陷，便有了下面的变长编码。

变长编码

单个编码的长度不一样，可以根据整体出现的频率来调节，出现的频率越高，编码长度越短。

变长编码优于定长编码的是，变长编码可以将短编码赋予平均出现频率较高的字符，同一消息的编码长度小于定长编码。

这个时候又有一个问题，字符有长有短，我们怎么知道一个字符从哪里开始，又从哪里结束呢？如果位数固定，就没这个问题了。

前缀属性

字符集其中的一个字符编码不是其他字符编码的前缀，则这个字符编码具有前缀属性。所谓前缀，一个编码可以被解码为多个字符，表示不唯一。比如，abcd需要编码表示，设a = 0，b = 10，c = 110，d = 11。那么110可以表示c，也可以表示da。不理解没关系，来看个例子。

字符	编码
P	000
Q	11
R	01
S	001
T	10

000不是11、01、001、10的前缀，000具有前缀属性。11不是000，01，001，10的前缀。

比如01001101100010 可以翻译为 RSTQPT。

又比如

字符	编码
P	0
Q	1
R	01
S	10
T	11

编码1110可以解码为QQQP、QTP，QQS和TS，对于任意一个编码，解码的结果不一样。

前缀码

所谓的前缀码，就是没有任何码字是其他码字的前缀。

问题

请设计变长的前缀编码，使用22位对消息DEAACAAAAABA进行编码。消息中字符A出现了8次，字符B、C、D、E均只出现了一次，字符A用一个bit表示， $A = 0$ 。其他字符的编码均不能以0开头， $B = 10$ 。 $C = 110$ $D = 1110$ $E = 11110$ 。刚刚好22位。当然也可以制定其他的几种。

所以哈夫曼编码就是一种前缀码。在构造这种编码的时候，就是用一颗哈夫曼树来进行构造的。

哈夫曼树的特征

1、哈夫曼编码树是一颗二叉树

- 每片叶子结点都包含一个字符
- 从结点到其左孩子的路径上标记0
- 从结点到其右孩子的路径上标记1

2、从根结点到包含字符的叶子结点的路径上获得的叶结点的编码

3、编码均具有前缀属性

- 每一个叶结点不能出现在到另一个叶结点的路径上
- 注意：定长编码可以由完整的哈夫曼树表示，并且显然具有前缀属性

有了哈夫曼编码树的特性，我们也知道了哈夫曼树的构造过程，最后我们再来看一个哈夫曼编码和哈夫曼树构造的完整过程。

示例

建立消息this is his message的一颗哈夫曼编码树

统计字符出现的次数

